

Coleta, Tratamento e Análise Exploratória de Dados da Loja Oficial da NBA via Web Scraping

Pedro Rufino da Mata Neto
Disciplina de Mineração de Dados
Fatec Araras – Antonio Brambilla
pedro.mata2@fatec.sp.gov.br

Gabriel Cardoso Schranck
Disciplina de Mineração de Dados
Fatec Araras – Antonio Brambilla
gabriel.schranck@fatec.sp.gov.br

Resumo—Este artigo apresenta o processo de coleta, tratamento e análise exploratória de dados obtidos a partir da loja virtual oficial da National Basketball Association (NBA). O trabalho foi desenvolvido no contexto da disciplina de Mineração de Dados, com o objetivo de construir uma base estruturada e consistente para aplicação de técnicas de descoberta de conhecimento. Utilizando web scraping com as bibliotecas BeautifulSoup, Requests e expressões regulares, foram coletados 3.118 registros distribuídos em 42 categorias de produtos. Na etapa de ETL e pré-processamento foram identificados problemas relevantes, como elevada quantidade de valores ausentes em algumas colunas, 2.362 duplicatas baseadas no campo SKU e presença de outliers na variável preço. Após as etapas de limpeza e transformação, a base final foi consolidada com 756 registros e 43 atributos. Os resultados demonstram a importância do pré-processamento para garantir a qualidade dos dados e evidenciam o potencial da base construída para análises futuras, como mineração de padrões, modelagem preditiva e construção de dashboards analíticos.

Index Terms—Web Scraping, Mineração de Dados, ETL, NBA, Pré-processamento de Dados, KDD, BeautifulSoup.

I. INTRODUÇÃO

O crescimento exponencial da quantidade de dados disponíveis na internet tem impulsionado o desenvolvimento de técnicas capazes de coletar, organizar e analisar essas informações de forma eficiente. Nesse cenário, o web scraping se destaca como uma abordagem importante para a obtenção automatizada de dados a partir de páginas web, especialmente quando não há APIs públicas disponíveis ou quando os dados desejados estão diretamente expostos em interfaces HTML.

No contexto do comércio eletrônico, a análise de dados de produtos permite identificar padrões de mercado, comportamento de consumo e tendências relevantes para diferentes tipos de decisão. Informações como preço, avaliações, marcas, categorias e descrições podem ser utilizadas em estudos de segmentação, previsão, recomendação e construção de indicadores analíticos.

Este trabalho foi desenvolvido no âmbito da disciplina de Mineração de Dados, com o objetivo de coletar, tratar e analisar exploratoriamente dados provenientes da loja virtual oficial da NBA. A escolha desse domínio se justifica pela grande variedade de produtos, pela presença de atributos numéricos, categóricos e textuais e pelo potencial de uso da base em etapas posteriores da disciplina.

Além disso, a base construída poderá ser explorada futuramente em questões como: quais atributos mais influenciam o preço dos produtos; como as marcas se distribuem em diferentes faixas de valor; se existe relação entre avaliações e quantidade de reviews; e quais padrões podem ser observados entre tipos de produtos. Assim, este artigo apresenta a construção da base e documenta o processo realizado até a etapa de pré-processamento dentro do fluxo de KDD.

II. FUNDAMENTAÇÃO TEÓRICA

A. Processo KDD

O processo de Descoberta de Conhecimento em Bases de Dados, conhecido como KDD (Knowledge Discovery in Databases), representa um conjunto de etapas voltadas à transformação de dados brutos em conhecimento útil. De forma geral, esse processo é composto por seleção, pré-processamento, transformação, mineração de dados e interpretação dos resultados [1].

A etapa de seleção consiste em definir o domínio do problema e identificar quais fontes de dados serão utilizadas. Em seguida, o pré-processamento busca reduzir ruídos, inconsistências, ausências e duplicidades que possam comprometer a qualidade das análises. A transformação envolve adequar os dados a formatos apropriados para exploração e modelagem. Posteriormente, são aplicadas técnicas de mineração de dados e, por fim, os resultados são interpretados no contexto do problema.

Neste trabalho, o foco está concentrado nas etapas iniciais do KDD, especialmente na seleção da fonte, coleta automatizada, limpeza e transformação dos dados, estabelecendo uma base confiável para as próximas fases da disciplina.

B. Web Scraping

Web scraping refere-se à extração automatizada de informações disponíveis em páginas web [2]. Em vez de consumir dados por interfaces programáveis formais, essa abordagem interpreta diretamente a estrutura HTML do site, identificando elementos específicos a partir de seletores, classes, atributos ou padrões textuais.

Essa técnica é amplamente utilizada em contextos acadêmicos e profissionais para obtenção de dados de produtos, notícias, indicadores públicos, oportunidades de emprego e diferentes tipos de catálogos. Entretanto, sua aplicação exige

atenção à estrutura da página, ao comportamento dinâmico gerado por JavaScript e às boas práticas de coleta.

De acordo com a literatura e com recomendações técnicas, é importante verificar as diretrizes disponíveis no arquivo `robots.txt`, utilizar um *User-Agent* apropriado, evitar excesso de requisições e respeitar os termos de uso da plataforma [3]. Esses cuidados são fundamentais para que a coleta ocorra de forma ética e tecnicamente adequada.

C. ETL e Pré-processamento

O processo de ETL (Extract, Transform, Load) é uma etapa central na preparação de dados [4]. Na fase de extração, os dados são obtidos da fonte original. Na fase de transformação, os valores passam por limpeza, padronização e adequação semântica. Já na carga, os dados são armazenados em um formato estruturado e apropriado para consulta ou análise.

Em cenários reais, dados coletados de páginas web frequentemente apresentam problemas como valores ausentes, colunas muito esparsas, redundâncias, ruídos textuais, formatações inconsistentes e outliers. Por isso, o pré-processamento se torna indispensável para garantir que a base final seja de fato utilizável em análises futuras [5].

III. METODOLOGIA

A. Definição do Problema e Fonte de Dados

A fonte de dados escolhida foi a loja virtual oficial da NBA, disponível em <https://www.lojanba.com/>. A escolha do site ocorreu devido à sua relevância comercial, à grande variedade de produtos licenciados e ao potencial analítico da base resultante. Por se tratar da principal liga de basquete do mundo, a NBA mantém um catálogo extenso que inclui camisetas, regatas, tênis, bonés, bolas, mochilas, moletons e outros acessórios esportivos.

Essa diversidade favorece a obtenção de uma base rica em atributos. Além disso, os dados coletados podem ser úteis para análises de precificação, segmentação de produtos, comparação entre marcas e identificação de padrões relacionados ao comportamento de consumo e ao posicionamento dos itens no catálogo.

B. Perguntas de Pesquisa

A construção da base visa apoiar, nas etapas seguintes da disciplina, a investigação de questões como:

- 1) Quais atributos influenciam mais fortemente o preço dos produtos?
- 2) Existe relação entre avaliação média e quantidade de avaliações?
- 3) Como diferentes marcas se distribuem em termos de preço e volume de produtos?
- 4) É possível identificar agrupamentos de produtos com características semelhantes?

C. Ferramentas e Bibliotecas

O desenvolvimento do projeto utilizou linguagem Python e as seguintes bibliotecas:

- **Requests**: utilizada para realizar as requisições HTTP às páginas do site;
- **BeautifulSoup**: empregada no parsing e navegação pela estrutura HTML;
- **re**: utilizada para expressões regulares, especialmente na extração de dados presentes em scripts JavaScript;
- **json**: usada para converter e manipular estruturas em formato JSON;
- **pandas**: responsável pela manipulação tabular, análise exploratória e transformação dos dados;
- **loguru**: empregada para logging e monitoramento das etapas do processo.

D. Processo de Web Scraping

O processo de scraping foi desenvolvido em etapas, desde a identificação das categorias até a coleta detalhada das informações de cada produto.

1) *Extração das Categorias*: Uma das principais dificuldades observadas foi que o menu de categorias não estava disponível de maneira simples no HTML estático da página principal. Após inspeção mais detalhada, verificou-se que os dados do menu eram inicializados via JavaScript dentro de uma estrutura chamada `__INITIAL_STATE__`.

Para contornar esse problema, foi empregada uma abordagem baseada em expressões regulares para localizar o conteúdo JSON embutido na página. Após a extração desse bloco, os dados foram convertidos com a biblioteca `json`, permitindo acessar a estrutura de navegação e recuperar os nomes e caminhos das categorias.

Com essa estratégia, foram identificadas 42 categorias de produtos, que serviram como ponto de partida para a coleta sistemática.

2) *Paginação e Navegação*: Após a extração das categorias, foi necessário compreender como o site organizava a paginação dos produtos. Verificou-se que a navegação entre páginas utilizava o parâmetro `&page`, iniciado em 1. Dessa forma, para cada categoria, o scraper passou a iterar sucessivamente sobre as páginas disponíveis até que não fosse mais encontrada uma lista válida de produtos.

Esse mecanismo permitiu a coleta escalável dos itens, respeitando a estrutura do site e tornando o processo mais simples de controlar programaticamente.

3) *Extração dos Atributos dos Produtos*: Para cada produto localizado nas páginas de listagem, o scraper acessava sua página individual e extraía os atributos relevantes. Os principais campos coletados foram:

- SKU;
- preço;
- cor;
- descrição;
- avaliação média;
- quantidade de avaliações;

- tamanho;
- imagens;
- URL do produto;
- atributos adicionais como marca, gênero, composição, origem e outros, quando disponíveis.

A extração foi facilitada porque o site apresenta uma estrutura HTML relativamente organizada, com classes CSS específicas para os elementos de interesse. Ainda assim, houve heterogeneidade entre tipos de produtos, o que exigiu tratamento flexível para campos ausentes ou opcionais.

Outro aspecto importante observado foi o tratamento das variações de cor. Inicialmente, considerou-se a possibilidade de navegar por URLs adicionais para capturar variações de um mesmo produto. Entretanto, foi identificado que o próprio site já exibía muitas dessas variações como itens separados em categorias distintas, permitindo sua captura sem a necessidade de um processo complementar.

E. Pipeline ETL

Após a coleta, os dados brutos foram estruturados em um pipeline de ETL composto pelas seguintes etapas:

- 1) extração dos dados via scraping;
- 2) estruturação inicial em lista de dicionários;
- 3) conversão para *DataFrame*;
- 4) análise exploratória inicial da qualidade da base;
- 5) limpeza e transformação dos dados;
- 6) exportação da base tratada em formato CSV.

F. Pré-processamento e Limpeza

A etapa de pré-processamento foi fundamental para melhorar a consistência da base. As transformações aplicadas incluíram:

- padronização dos nomes das colunas;
- limpeza do campo SKU, removendo caracteres inválidos e padronizando letras maiúsculas;
- remoção de registros com SKU vazio;
- remoção de duplicatas com base no SKU;
- normalização de campos textuais;
- conversão dos campos numéricos, especialmente preço, avaliação média e número de reviews;
- preenchimento de valores ausentes com critérios diferentes para variáveis numéricas e categóricas;
- remoção de colunas excessivamente esparsas;
- padronização de categorias textuais;
- detecção de outliers usando o método do intervalo interquartil (IQR);
- criação de uma variável categórica de faixa de preço;
- normalização Min-Max da variável preço;
- limpeza textual do campo descrição.

Esse conjunto de etapas permitiu transformar uma base bruta e ruidosa em um conjunto mais adequado para análises posteriores.

IV. RESULTADOS

A. Panorama da Base Bruta

A etapa de coleta resultou em 3.118 registros brutos provenientes de 42 categorias. A análise inicial mostrou que, embora a coleta tenha sido bem-sucedida em termos de volume, a base ainda apresentava problemas importantes de qualidade.

Entre os principais problemas identificados estavam a alta taxa de duplicidade e a presença de colunas com percentuais elevados de valores ausentes. Em algumas variáveis, como Classificação Indicativa, Console, Categoria, Pisada e outras, o percentual de ausência chegou a aproximadamente 99,9%. Por outro lado, variáveis essenciais como sku, value, media_rating, number_reviews, size, images, url_product, Nome, Marca e color apresentaram preenchimento completo ou quase completo.

B. Duplicatas e Qualidade dos Dados

Foram identificadas 2.362 duplicatas com base no campo SKU. Esse volume representa a maior parte dos registros brutos e indica que o mesmo produto era apresentado em múltiplos contextos dentro do catálogo, especialmente quando aparecia em diferentes categorias ou listagens.

Além disso, não foram encontrados preços inválidos iguais ou inferiores a zero na análise inicial. Ainda assim, a variável preço apresentou presença de outliers, totalizando 67 casos detectados pelo método IQR. Esses valores não foram necessariamente removidos da base, mas foram identificados para apoiar análises futuras e evidenciar a heterogeneidade dos produtos disponíveis.

C. Comparativo Antes e Depois da Limpeza

Após a aplicação das etapas de limpeza e transformação, a base passou de 3.118 registros para 756 registros finais. Esse resultado mostra que o pré-processamento teve forte impacto na consolidação da base, principalmente em razão da remoção de duplicatas.

O comparativo pode ser resumido da seguinte forma:

- registros antes da limpeza: 3.118;
- duplicatas removidas por SKU: 2.362;
- outliers detectados na variável preço: 67;
- registros após a limpeza: 756.

A redução expressiva da base não representa perda indevida de dados, mas sim a consolidação de registros redundantes e a eliminação de inconsistências que poderiam comprometer etapas posteriores de mineração.

D. Estrutura da Base Final

A base final consolidada passou a contar com 43 atributos, distribuídos entre variáveis numéricas, categóricas e textuais. Entre os atributos mais relevantes estão:

- **numéricos:** preço, avaliação média, quantidade de avaliações e preço normalizado;
- **categóricos:** marca, gênero, cor, tamanho e faixa de preço;

- **textuais:** descrição, nome do produto e URL.

Esse conjunto atende ao requisito mínimo estabelecido pela atividade, que exigia ao menos 1.000 registros brutos e, na base construída, um mínimo de seis campos com pelo menos três numéricos e dois categóricos. Embora a base final tenha sido reduzida após limpeza, o volume inicialmente coletado atendeu à exigência e o resultado tratado tornou-se mais consistente para as análises futuras.

E. Interpretação dos Resultados

Os resultados obtidos evidenciam dois pontos principais. O primeiro é que a coleta automatizada em ambientes reais costuma produzir dados redundantes, incompletos e heterogêneos, exigindo um processo cuidadoso de tratamento. O segundo é que, mesmo após uma forte redução na quantidade de registros, a base resultante continua suficientemente rica em volume e variedade de atributos para aplicações de mineração de dados.

A presença de atributos como preço, reviews, avaliação, marca, gênero, categoria textual e características adicionais dos produtos fornece uma base promissora para tarefas como análise exploratória aprofundada, classificação, agrupamento e visualização analítica.

V. CONCLUSÃO

Este trabalho apresentou o desenvolvimento de um processo completo de coleta, tratamento e análise exploratória de dados da loja oficial da NBA por meio de web scraping. Foram coletados 3.118 registros brutos, que após as etapas de pré-processamento e consolidação resultaram em 756 registros finais com 43 atributos.

Os resultados reforçam a importância da etapa de pré-processamento no contexto de mineração de dados, uma vez que a base original apresentava quantidade elevada de duplicatas, colunas muito esparsas e heterogeneidade entre atributos. Sem esse tratamento, a utilização da base em análises futuras seria limitada e potencialmente imprecisa.

Entre os principais aprendizados do projeto destacam-se a necessidade de lidar com estruturas dinâmicas carregadas via JavaScript, a importância da padronização de campos e a relevância de decisões metodológicas bem documentadas durante o ETL. Também ficou evidente que a simples coleta de um grande volume de dados não garante qualidade analítica, sendo indispensável o tratamento criterioso das informações.

Como próximos passos, a base construída poderá ser utilizada em técnicas de mineração de dados, como classificação, clusterização e análise de associações, além da construção de dashboards para exploração visual dos padrões identificados. Dessa forma, o presente trabalho se posiciona claramente nas etapas de seleção, pré-processamento e transformação do processo KDD, servindo como base para as próximas fases da disciplina.

REFERÊNCIAS

- [1] U. Fayyad, G. Piatetsky-Shapiro, and P. Smyth, "From Data Mining to Knowledge Discovery in Databases," *AI Magazine*, vol. 17, no. 3, pp. 37–54, 1996.
- [2] R. Lawson, *Web Scraping with Python*. Birmingham, UK: Packt Publishing, 2015.
- [3] R. Mitchell, *Web Scraping with Python: Collecting More Data from the Modern Web*, 2nd ed. Sebastopol, CA: O'Reilly Media, 2018.
- [4] R. Kimball and M. Ross, *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*, 3rd ed. Indianapolis, IN: John Wiley & Sons, 2011.
- [5] J. Han, M. Kamber, and J. Pei, *Data Mining: Concepts and Techniques*, 3rd ed. San Francisco, CA: Morgan Kaufmann, 2011.
- [6] L. Richardson, "Beautiful Soup Documentation," [Online]. Available: <https://www.crummy.com/software/BeautifulSoup/bs4/doc/>
- [7] K. Reitz, "Requests: HTTP for Humans," [Online]. Available: <https://docs.python-requests.org/>
- [8] The pandas development team, "pandas: Python Data Analysis Library," [Online]. Available: <https://pandas.pydata.org/>