

Desenvolvimento de Dashboard Analítico e Aplicação de Aprendizado Supervisionado sobre o Portfólio de Produtos da Loja Oficial da NBA

*Disciplina de Mineração de Dados — Trabalho Prático Fase 2

Pedro Rufino da Mata Neto
Curso de Tecnologia em ADS
Fatec Araras Antonio Brambilla
Araras, Brasil
pedro.mata2@aluno.sp.gov.br

Gabriel Cardoso Schranck
Curso de Tecnologia em ADS
Fatec Araras Antonio Brambilla
Araras, Brasil
gabriel.schranck@aluno.sp.gov.br

Resumo—Este trabalho apresenta a Fase 2 do projeto prático de Mineração de Dados, dando continuidade ao processo de Descoberta de Conhecimento em Bancos de Dados (KDD) iniciado na etapa anterior. A partir do ecossistema consolidado de produtos da loja virtual da National Basketball Association (NBA), implementou-se um ambiente de Business Intelligence utilizando a ferramenta open-source Metabase alimentada de forma direta por arquivos de dados estruturados. Foram desenvolvidas visualizações analíticas interativas interligadas por filtros dinâmicos de interface, permitindo investigar o comportamento de precificação, engajamento e distribuições mercadológicas de marcas. Complementarmente, aplicou-se uma abordagem de aprendizado de máquina supervisionado baseada no algoritmo de Árvore de Decisão para classificar e prever o posicionamento de produtos na categoria de preços elevados (Premium). Os resultados demonstraram uma acurácia preditiva de 67,10% e um F1-Score de 71,91%, evidenciando a eficácia da convergência entre a análise exploratória visual e a modelagem estatística preditiva.

Index Terms—Data Mining, Metabase, Arquivos CSV, Árvore de Decisão, E-commerce, NBA.

I. INTRODUÇÃO

O monitoramento e a extração de inteligência competitiva no comércio eletrônico moderno exigem ferramentas analíticas robustas, capazes de traduzir grandes volumes de dados brutos em insumos estratégicos operacionais. No cenário dinâmico do e-commerce de artigos desportivos de alta relevância global, como a loja oficial da NBA, compreender as complexas correlações entre posicionamento de preço, reputação de marca e engajamento do consumidor é vital para mitigar riscos de inventário e otimizar margens de contribuição.

Esta Fase 2 concretiza as etapas finais do processo KDD (*Knowledge Discovery in Databases*), concentrando esforços nas fases de Visualização, Avaliação e Interpretação. O objetivo central deste documento é relatar a estruturação de um painel gerencial dinâmico no Metabase integrado a uma camada de persistência baseada em arquivos planos estruturados, a formalização de perguntas analíticas complexas orientadas ao negócio e a validação de uma hipótese preditiva por meio

de técnicas de inteligência artificial. Com este arcabouço tecnológico e analítico, busca-se munir gestores com *insights* prescritivos capazes de otimizar o mix de produtos de marcas parceiras (como Nike, Adidas, Mitchell & Ness e Wilson) e prever o comportamento de aceitação e posicionamento de mercado de novos itens antes de sua inclusão definitiva no catálogo ativo.

II. BASE DE DADOS E INFRAESTRUTURA

A. Tratamento e Consolidação do Dataset

A base de dados utilizada nesta fase é a evolução direta da estrutura obtida via extração automatizada (*web scraping*) executada na Fase 1 do projeto prático. O processo bruto de coleta na plataforma online da NBA capturou originalmente 3.118 registros distribuídos em múltiplas categorias estruturais. Após o tratamento rigoroso de limpeza e higienização — que incluiu a remoção de 2.362 duplicatas baseadas no critério de integridade estrita do SKU, eliminação de registros com valores omissos em campos críticos e o tratamento de *outliers* de preço via método de amplitude interquartilica —, o *dataset* final foi estabilizado em 756 amostras consistentes altamente estruturadas.

Para fins de conformidade regulamentar com os critérios metodológicos da disciplina, a base de dados assegura um histórico agregado robusto pré-tratamento e uma amostragem tratada que supera significativamente os limites mínimos exigidos. Os dados contemplam variáveis contínuas, inteiras e categóricas nominais. O Dicionário de Dados focado nas camadas analíticas do dashboard e de Machine Learning é detalhado na Tabela I.

B. Arquitetura de Carga e Armazenamento

Diferente de arquiteturas corporativas baseadas em servidores de bancos de dados relacionais dedicados e complexos, a infraestrutura deste projeto foi desenhada prezando pela leveza e velocidade de homologação. O ecossistema analítico

Tabela I
DICIONÁRIO DE ATRIBUTOS SELECIONADOS PARA ANÁLISE

Atributo	Tipo de Dado	Descrição Conceitual
sku	Catégorico (Texto)	Identificador único universal do produto no catálogo.
marca	Catégorico (Texto)	Fabricante ou licenciadora do item (ex: Nike, Adidas, Puma).
gênero	Catégorico (Texto)	Segmentação demográfica de público (Masculino, Feminino, Unissex).
value	Númérico (Contínuo)	Preço final de venda praticado na plataforma em R\$.
media_rating	Númérico (Contínuo)	Nota média de avaliações dos consumidores (0.0 a 5.0).
number_reviews	Númérico (Inteiro)	Volume absoluto de avaliações recebidas pelo produto.

utiliza o arquivo plano `product.csv` de forma direta como repositório primário de persistência.

A ferramenta de Business Intelligence Metabase foi implantada localmente e configurada para consumir o arquivo de texto estruturado através de seu mecanismo integrado de ingestão. O Metabase analisa semanticamente a primeira linha do arquivo para determinar o esquema de metadados, mapeando os delimitadores de coluna e convertendo os tipos de texto brutos em tipos de dados reconhecidos pelo motor analítico em sua camada embutida. Essa estratégia garante portabilidade imediata, permitindo que toda a inteligência visual do projeto seja reconstruída e distribuída bastando o compartilhamento do arquivo de dados e da aplicação cliente.

III. PERGUNTAS ANALÍTICAS

Para guiar o desenvolvimento do ecossistema analítico e garantir que a exploração não fosse puramente descritiva ou estática, formularam-se três perguntas complexas de negócio, orientadas ao contexto macroeconômico do varejo eletrônico desportivo:

- **Pergunta 1 (P1):** Quais marcas concentram as maiores médias de preço de venda e como os volumes potenciais de estoque e faturamento estão distribuídos no catálogo da NBA?
- **Pergunta 2 (P2):** Existe variação significativa e perceptível na reputação e satisfação do cliente (*media_rating*) entre as grandes marcas fornecedoras, excluindo os itens sem engajamento?
- **Pergunta 3 (P3):** É possível modelar e prever se um novo produto será classificado na faixa de preço superior (Premium) utilizando unicamente suas propriedades categóricas de origem e indicadores de engajamento iniciais?

A rastreabilidade e cobertura de cada indagação pelas frentes tecnológicas e analíticas implementadas são mapeadas de forma transparente na Tabela II.

Tabela II
MAPEAMENTO DE COBERTURA DAS PERGUNTAS ANALÍTICAS

Pergunta	Respondida pelo Dashboard?	Respondida por ML?
P1	Sim (Gráficos 2 e 3)	Não
P2	Sim (Gráfico 1)	Não
P3	Parcialmente (Gráficos 4 e 5)	Sim (Árvore de Decisão)

IV. DASHBOARD (METABASE)

O painel gerencial desenvolvido no Metabase foi projetado seguindo as melhores práticas de *User Experience* (UX) analítica, priorizando a densidade de informação e o dinamismo em detrimento de exibições estáticas. No topo da interface gráfica, implementou-se um componente de filtragem global do tipo *Dropdown* acoplado à coluna *marca*. Ao interagir com a interface, o usuário propaga restrições condicionais que alteram as consultas em execução, atualizando as 5 visualizações em tempo real. As 5 visões obrigatórias foram estruturadas da seguinte forma:

- 1) **Gráfico 1 (Ranking de Satisfação por Marca):** Exibição em barras horizontais ordenadas de forma decrescente correlacionando a métrica *media_rating* por fabricante. Aplicou-se um filtro de exclusão estrutural para desconsiderar produtos com nota exatamente igual a 0.0, mitigando distorções estatísticas provocadas por itens sem interações e isolando a reputação real das marcas ativas.
- 2) **Gráfico 2 (Posicionamento Médio de Preço):** Gráfico de colunas verticais que plota a média aritmética do atributo *value* segmentada por marca. Permite identificar de imediato quais marcas adotam estratégias de precificação agressivas e quais focam em produtos de entrada.
- 3) **Gráfico 3 (Histograma de Densidade de Catálogo):** Distribuição de frequência que agrupa a variável contínua *value* em intervalos automáticos de valor (*bins*). Essencial para diagnosticar a concentração de preços da loja e identificar zonas de elasticidade.
- 4) **Gráfico 4 (Composição Demográfica do Portfólio):** Gráfico de rosca focado na quebra percentual dos SKUs mapeados com base no atributo *gênero*, expondo o direcionamento de público-alvo adotado pela plataforma de vendas.
- 5) **Gráfico 5 (Dispersão de Engajamento vs. Preço):** Um *Scatter Plot* de alta densidade que cruza o preço de venda (*value*) no Eixo X contra a volumetria absoluta de interações (*number_reviews*) no Eixo Y, evidenciando graficamente a presença de agrupamentos de consumo ou *outliers* de engajamento.

V. TÉCNICA DE APRENDIZADO DE MÁQUINA

A. Escolha e Justificativa do Algoritmo

Para responder com rigor matemático, preditivo e reproduzível à **Pergunta 3 (P3)**, adotou-se o paradigma de Aprendizado Supervisionado por meio do algoritmo de **Árvore de Decisão** (*Decision Tree Classifier*). A escolha dessa técnica justifica-se pela necessidade crítica de interpretabilidade no cenário corporativo. Ao contrário de modelos do tipo "caixa-preta" (como Redes Neurais), as Árvores de Decisão geram regras explícitas de classificação fundamentadas em estruturas hierárquicas condicionais, permitindo que analistas de mercado auditem e compreendam com facilidade os caminhos lógicos que determinam a precificação de um produto.

B. Fundamentação e Formulação Técnica

O algoritmo opera dividindo recursivamente o espaço de busca dos dados a fim de maximizar a homogeneidade (pureza) dos nós filhos gerados. Para mensurar a eficiência de cada quebra sequencial, utilizou-se o critério do **Índice de Gini**, expresso matematicamente pela Equação (1):

$$I_G(t) = 1 - \sum_{i=1}^c p_i^2 \quad (1)$$

Onde p_i representa a probabilidade de uma instância pertencer à classe i no nó t . O algoritmo busca selecionar, a cada nível, o atributo e o ponto de corte que maximizem a redução do Índice de Gini global.

- **Variável Alvo (Y):** Foi construída a variável binária **premium**. Calculou-se a mediana exata de preços de toda a base ativa (R\$ 209,99). Os registros com preço estritamente superior receberam rótulo 1 (Premium), enquanto os demais foram classificados como 0 (Standard).
- **Variáveis Preditores (X):** O vetor de características incluiu as colunas categóricas **marca** e **gênero** (convertidas via *Label Encoding* para vetores numéricos inteiros), além das contínuas **media_rating** e **number_reviews**.
- **Metodologia de Validação:** O conjunto total de dados (756 instâncias) foi fracionado utilizando a amostragem clássica Holdout, separando 80
- **Mitigação de Overfitting:** Para garantir a capacidade de generalização do modelo diante de novos dados, aplicou-se uma poda prévia limitando a profundidade máxima da árvore (**max_depth=3**). Essa restrição evita que o classificador decore ruídos do conjunto de treino, mantendo a estrutura enxuta e altamente interpretável.

C. Análise dos Resultados Obtidos

Após a execução e evolução do algoritmo sobre a matriz de validação carregada diretamente do arquivo estruturado, as métricas de desempenho quantitativas foram consolidadas e estão detalhadas na Tabela III.

A análise das métricas revela um comportamento de alta relevância estratégica: o modelo alcançou uma sensibilidade (*Recall*) expressiva de 86,48%. Isso indica que o classificador

Tabela III
MÉTRICAS DE DESEMPENHO DO MODELO PREDITIVO

Métrica Estatística de Avaliação	Valor Percentual Obtido
Acurácia Geral (<i>Accuracy</i>)	67,10%
Precisão (<i>Precision</i> - Classe 1)	61,53%
Sensibilidade (<i>Recall / True Positive Rate</i>)	86,48%
F1-Score Combinado (Média Harmônica)	71,91%

possui uma taxa de erro do Tipo II baixíssima, sendo altamente eficiente em rastrear e identificar produtos de valor elevado com base no comportamento de engajamento e atributos iniciais, errando raramente na classificação de itens efetivamente premium.

VI. RESPOSTAS ÀS PERGUNTAS ANALÍTICAS

A. Resposta à Pergunta 1 (P1)

A análise exploratória integrada dos Gráficos 2 e 3 do Metabase indicou que marcas como Adidas e Nike exercem um posicionamento de preço visivelmente superior no catálogo, concentrando as maiores médias de valor por peça. O histograma de distribuição revelou uma densidade assimétrica à direita: embora haja uma massa volumosa de produtos concentrada em faixas acessíveis (abaixo de R\$ 150,00), a presença de itens assinados por atletas e coleções especiais eleva significativamente a média e o faturamento potencial bruto estimado da plataforma.

B. Resposta à Pergunta 2 (P2)

O Gráfico 1 (Ranking de Avaliação) desmistificou o cenário de avaliações brutas. Após o expurgo metodológico das notas 0.0 (produtos sem nenhuma interação), constatou-se uma estabilidade qualitativa rigorosa entre as principais fabricantes. As médias ponderadas flutuam de forma estável entre os limiares de 4.4 e 4.8. Isso demonstra que não há variação discrepante de qualidade percebida pelo cliente entre as grandes marcas parceiras da NBA, sugerindo que a experiência do consumidor mantém-se uniformemente satisfatória e padronizada.

C. Resposta à Pergunta 3 (P3)

A modelagem estatística supervisionada confirmou de forma positiva a viabilidade da predição automatizada. Alcançando uma acurácia global de 67,10% e uma estabilidade estrutural medida pelo F1-Score de 71,91%, comprovou-se matematicamente que o perfil categórico de origem de um produto (marca licenciadora e público-alvo) combinado ao comportamento de engajamento do consumidor em suas fases iniciais (**number_reviews**) fornece sinal estatístico suficiente para antecipar com segurança o enquadramento de precificação Premium de novos itens inseridos no inventário da e-commerce.

VII. CONCLUSÃO

Este trabalho concluiu com êxito todas as etapas estabelecidas para a Fase 2 da disciplina de Mineração de Dados. A transição e evolução do processo de extração bruta via

raspagem de dados (Fase 1) para uma arquitetura ágil e de alta portabilidade, alimentando o ambiente analítico do Metabase de forma direta com arquivos CSV planos, eliminou a opacidade das tabelas originais e acelerou a entrega de valor.

A introdução da modelagem de Inteligência Artificial por meio da Árvore de Decisão adicionou valor estatístico e prescritivo ao projeto, transformando dados puramente históricos em um motor de auxílio à tomada de decisão capaz de classificar tendências de mercado. Como proposta para investigações futuras, recomenda-se a expansão do vetor de características através da aplicação de técnicas de Processamento de Linguagem Natural (PLN), extraindo *features* textuais diretamente da descrição dos produtos (*description*) para enriquecer o poder preditivo do classificador.

REFERÊNCIAS

- [1] U. Fayyad, G. Piatetsky-Shapiro, and P. Smyth, “From Data Mining to Knowledge Discovery in Databases,” *AI Magazine*, vol. 17, no. 3, pp. 37-54, 1996.
- [2] Metabase Open Source Documentation (v0.61). Disponível em: <https://www.metabase.com/docs/>. Acesso em: 2026.
- [3] F. Pedregosa *et al.*, “Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825-2830, 2011.
- [4] J. R. Quinlan, “Induction of Decision Trees,” *Machine Learning*, vol. 1, no. 1, pp. 81-106, 1986.